Ciência de Dados – Projeto Final

Análise de Dados Aplicada

Prof. Dr. Eduardo Pena

Neste trabalho, cada grupo deverá investigar um problema relacionado ao sistema elétrico brasileiro, desde a preparação dos dados até a análise e a modelagem preditiva. O objetivo é **tomar decisões justificadas, testar hipóteses e interpretar resultados**.

Grupos: até 4 alunos.

Ferramentas: Python (pandas, scikit-learn e bibliotecas de visualização), DuckDB ou PostgreSQL e Git. Outras ferramentas podem ser utilizadas quando necessário.

1. Definição do problema – primeira semana

A fonte principal deve ser o **Portal de Dados Abertos do ONS**. O grupo pode investigar carga elétrica, geração de energia, picos de demanda ou outras variáveis disponíveis. Os dados devem ser **obtidos diretamente do portal**: não é permitido utilizar uma base já limpa, agregada ou enriquecida por terceiros como dataset principal.

Durante a primeira semana, o grupo deve explorar a documentação e alguns arquivos para decidir:

- **Problema e hipóteses:** formular 1–2 perguntas de pesquisa e 2–3 hipóteses testáveis. As perguntas devem permitir uma investigação e uma tarefa preditiva bem definidas.
- **Recorte dos dados:** definir variável-alvo, subsistema ou região e período de análise, verificando se há dados suficientes.
- **Granularidade e horizonte:** escolher se a análise será horária, diária, semanal ou mensal e **com quanta antecedência** a previsão será feita. Justificar as duas escolhas.
- **Integração prevista:** indicar as fontes de clima e feriados e como esses dados poderão ser associados aos registros do ONS.

Por exemplo, o grupo pode prever a carga máxima do dia seguinte, investigar a ocorrência de picos de demanda ou prever a geração média do próximo mês. **A primeira semana termina com a definição do problema.** Alterações posteriores devem ser justificadas.

2. Preparação e integração dos dados

Baixe os arquivos originais do ONS e prepare a base para análise. O grupo deverá realizar as próprias **agregações temporais**, além de tratar dados ausentes, duplicados, formatos de datas e valores suspeitos. Documente as decisões tomadas e mantenha o processo reproduzível.

É **obrigatório integrar dados climáticos e de feriados**. Para clima, podem ser utilizados INMET ou Open-Meteo; para feriados, calendários oficiais ou a biblioteca `holidays`. A inclusão de **indicadores econômicos** (IBGE, IPEADATA, Banco Central) é encorajada quando fizer sentido para o problema.

A integração deve considerar a escala temporal e geográfica. Explique, por exemplo, quais municípios ou estações representam um subsistema, como as temperaturas são agregadas e como os feriados são associados aos dados. O resultado deve ser uma base bem organizada (*tidy data*), exportada em **Parquet**, juntamente com os scripts ou notebooks necessários para reproduzi-la.

3. Investigação dos dados e consultas SQL

Utilize **pelo menos 5 consultas SQL** para responder a perguntas sobre o conjunto de dados. Inclua agregações por período e, quando pertinentes, **CTEs e funções de janela** para médias móveis, comparações e tendências. Cada consulta deve ser acompanhada de uma breve interpretação do resultado.

A análise exploratória deve investigar padrões relevantes para o problema, por exemplo:

- **Comportamento temporal:** variações por hora, dia da semana, mês e ano; tendências e sazonalidade.
- **Comparações:** diferenças entre períodos, subsistemas, dias úteis e feriados.
- **Relação com o clima:** associações com temperatura, chuva ou outras variáveis integradas.
- **Eventos excepcionais:** períodos de demanda ou geração muito acima ou abaixo do habitual e possíveis explicações.

Teste as hipóteses definidas na primeira semana com métodos estatísticos adequados, como testes de hipóteses, intervalos de confiança. Apresente gráficos e resultados interpretados. Não basta mostrar correlações ou médias: explique o que foi observado, quais conclusões os dados sustentam e como isso orienta a modelagem.

4. Modelagem e experimentos

Prepare a série temporal para aprendizado supervisionado, respeitando o horizonte de previsão escolhido. Construa atributos a partir de valores anteriores (*lags*), médias móveis, calendário e variáveis integradas. Justifique os atributos utilizados.

Modelos obrigatórios:

1. **Baseline temporal:** uma previsão simples baseada no histórico, por exemplo o valor de um período equivalente anterior.
2. **Dois modelos convencionais:** escolha entre regressão linear/logística, Random Forest, SVM/SVR ou outros adequados ao problema.
3. **Gradient boosting:** utilize XGBoost, LightGBM ou CatBoost.
4. **TabPFN:** tente utilizar TabPFN ou TabPFN-TS. Se houver limitações de dados ou recursos computacionais, documente a tentativa e os motivos; uma amostra temporal justificada é aceitável.

Validação temporal. Separe treino, validação e teste em ordem cronológica, reservando o período mais recente para avaliação final. Realize *tuning* com validação temporal (janelas sucessivas ou expansivas). **Não use divisão aleatória** de observações nem o conjunto de teste para escolher atributos ou hiperparâmetros.

Evite vazamento de dados. Uma previsão só pode utilizar informações disponíveis no instante em que seria feita. Isso inclui lags, médias móveis e dados externos: valores meteorológicos observados depois desse instante não podem ser utilizados como se já fossem conhecidos. Considere o horizonte escolhido ao construir cada atributo.

Experimentos com integração. Compare o desempenho com histórico e calendário básico, depois com feriados, com clima e com a combinação dessas fontes. Se houver indicadores econômicos, analise também a contribuição deles. Utilize as mesmas divisões temporais nas comparações.

Avaliação. Use métricas adequadas (como MAE/RMSE para regressão ou precisão, recall e F1 para classificação). Apresente valores reais e previstos, investigue **quando os modelos erram mais** – por exemplo, em picos, feriados ou períodos específicos – e discuta se o ganho dos modelos mais complexos compensa a complexidade. Justifique a escolha final.

5. Relatório e apresentação

O **relatório técnico** deve ter **6–8 páginas**, sem contar referências. Apresente o problema, os dados e sua preparação, as principais descobertas da investigação, a metodologia de previsão, a comparação dos experimentos e a análise dos erros. Termine respondendo às perguntas de pesquisa e discutindo as limitações. Selecione os resultados mais importantes; não é necessário incluir todos os gráficos ou testes.

A **apresentação** terá **13–15 minutos**, com participação equilibrada dos integrantes. Mostre o problema e as escolhas feitas, a integração dos dados, as descobertas principais, os resultados dos modelos e as conclusões. Os notebooks e scripts devem estar em um repositório Git organizado, com instruções para reproduzir o trabalho.

Importante: o relatório deve ser escrito integralmente pelos alunos. O uso de IA é permitido apenas para correção de texto já produzido pelos estudantes.

Entregas por etapa

Etapa	O que entregar
1. Proposta	**PDF de 1–2 páginas**, com integrantes e link do Git, problema, perguntas, hipóteses, dados selecionados, granularidade, horizonte e fontes previstas. **Ao final da primeira semana.**
2. Dados	Notebook/scripts que obtenham e preparem os dados originais do ONS, façam as agregações e a integração com clima e feriados; **base final em Parquet**.
3. Análise	Notebook com **5+ consultas SQL** comentadas, gráficos interpretados, testes das hipóteses e principais descobertas.
4. Modelos	Notebook com atributos temporais, baseline, modelos obrigatórios, tentativa com TabPFN, tuning, validação temporal, comparação com e sem as fontes integradas e análise dos erros.
5. Final	**Relatório PDF, slides e Git** com pipeline executável e instruções de reprodução.